

Actividad del Módulo 1: Creación de la Base de Conocimiento Semántico y Sistema Q&A (Preguntas y Respuestas)

Objetivo:

Diseñar y construir el núcleo de conocimiento para un futuro asistente virtual (chatbot) de una empresa líder del Valle del Cauca. Los estudiantes deberán extraer información pública de la empresa asignada, procesarla, y crear un sistema básico de Preguntas y Respuestas (Q&A) utilizando técnicas de Prompt Engineering. Esta base será el "cerebro" del chatbot que se desarrollará en los siguientes módulos.

Descripción de la Actividad:

En los mismos grupos de 4 personas, a cada equipo se le asignará una empresa del listado de las "500 Empresas más importantes del Valle". La tarea de este primer módulo es construir y validar la capa de conocimiento de la empresa.

Instrucciones Detalladas:

1. Asignación de Empresa y Análisis Inicial (Investigación):

- **Asignación:** Se asignará una empresa del Top 50 a cada grupo (ej. Grupo 1: CELSIA, Grupo 2: TECNOQUÍMICAS, etc.).
- **Investigación:** Los estudiantes deben realizar una investigación exhaustiva de la empresa asignada para identificar sus fuentes de información pública y digital:
 - Sitio web oficial (secciones "Quiénes somos", "Nuestros productos/servicios", "Sostenibilidad", "Informes de gestión", "Noticias/Blog").
 - Perfiles en redes sociales (LinkedIn, Instagram, Facebook, etc.).
 - Apariciones en medios de comunicación locales y nacionales (noticias, entrevistas).
- **Definición del Alcance:** El grupo debe definir qué tipo de preguntas debería poder responder un cliente al interactuar por primera vez con la empresa (ej: horarios, sedes, tipos de productos, historia de la empresa, información de contacto, procesos básicos).

2. Construcción de la Base de Conocimiento Semántico (Knowledge Base):

- **Extracción de Datos:** Utilizando librerías de Python como requests y BeautifulSoup, Selenium, los estudiantes deberán hacer web scraping del sitio web de su empresa para extraer el contenido textual relevante.
- **Preprocesamiento y Segmentación (Chunking):** El texto extraído debe ser limpiado (eliminar HTML, etc.) y dividido en fragmentos más pequeños y semánticamente coherentes (chunks).
- **Nota:** Este punto es práctico, se debe entregar el repositorio con todos los códigos utilizados y la base de conocimiento proveniente del web scrapping.

3. Construcción del Aplicativo:

- **Selección del Modelo y Framework:** Los estudiantes decidirán si usar un modelo Open Source a través de **Ollama** (ej. Llama 3.2, Mistral) o un modelo privado vía **API de OpenAI** (ej. GPT-5, Gemini 2.5 Pro). Deberán utilizar un **Framework de LLM** (se recomienda **LangChain** o **LlamaIndex**) para orquestar el proceso.
- **Aplicación de Prompt Engineering:** Diseñarán un prompt robusto que instruya al LLM para que responda la pregunta del usuario **basándose únicamente en el contexto proporcionado**. Deberán experimentar con técnicas como zero-shot, el formato del prompt y las instrucciones para evitar alucinaciones.
- Tomen todo el texto limpio que extrajeron en el "Punto 2" (tras el web scraping) y consolídenlo en el prompt de sistema. Este prompt será la "memoria" o el "cerebro" completo de su asistente en esta primera fase.

4. Desarrollo de una Interfaz de Prueba:

- Para facilitar la prueba y la demostración, los estudiantes desarrollarán una interfaz de usuario web simple utilizando **Streamlit** o **Gradio**. Esta interfaz debe tener un campo para escribir una pregunta y un área donde se muestre la respuesta generada por el sistema.

5. Pruebas, Documentación y Presentación:

- **Pruebas:** Realizarán pruebas exhaustivas formulando al menos 20 preguntas distintas (relacionadas al alcance definido en el paso 1) para evaluar la precisión y coherencia de las respuestas.
- **Documentación (Informe):** El informe deberá seguir la estructura solicitada de las secciones:
 - **Descripción del problema:** "Necesidad de un canal de comunicación automatizado y preciso para la empresa X".
 - **Planteamiento de la solución:** "Creación de un sistema Q&A basado en RAG como núcleo para un futuro chatbot".
 - **Preparación de los datos:** Detallar el proceso de scraping, limpieza y chunking.
 - **Modelado:** Explicar la elección del modelo de embedding, el LLM que van a utilizar en el modulo 2, la base de datos vectorial y el diseño del prompt.
 - **Resultados:** Mostrar ejemplos de preguntas y respuestas, analizar la calidad de las mismas y discutir las limitaciones encontradas.
- **Presentación:** La sustentación será en vivo (15 minutos), donde deberán explicar el proceso y realizar una demostración funcional de su sistema Q&A a través de la interfaz de Streamlit/Gradio. **NO HACER PRESENTACIONES DE POWERPOINT**